

Бизнес-постановка

Т-Инвестиции - крупнейший брокер в России, предоставляющий клиентам широкий спектр инвестиционных инструментов. Для повышения эффективности маркетинговых кампаний, персонализации предложений и увеличения комиссионного дохода бизнесу необходимо выявлять клиентов, которые с высокой вероятностью станут активными инвесторами в течение первых 3 месяцев после начала использования платформы. Это позволит:

1. адресно предлагать таким клиентам продвинутые инструменты (фьючерсы, структурные продукты) и обучающие материалы;
2. оптимизировать бюджет на привлечение и удержание, концентрируя усилия на перспективной аудитории;
3. адаптировать интерфейс и коммуникации под сегменты с разным потенциалом активности.

ML-постановка

Задача сводится к бинарной классификации: по доступным на раннем этапе данным (социально-демографические характеристики, начальные балансы, первичные действия) предсказать, станет ли клиент активным инвестором в течение первых 3 месяцев.

Целевая переменная - бинарный флаг is_active. Активным считается клиент, у которого за первые 3 месяца:

- суммарный оборот по любым инструментам > 0 или
- количество торговых поручений ≥ 1 или
- стоимость портфеля превышает медианное значение (8765 руб.) и имеется ненулевая активность по оборотам.

Признаки включают: возраст, образование, семейное положение, количество детей, ежемесячный доход, флаги (`forts_flg`, `margin_status_flg`, `qualified_investor_flg`), начальные балансы (`ccr_balance_amt`, `cor_balance_amt`), сумму первого пополнения, а также показатели социальной активности (`posts`, `comments`, `reacts`, `reads`) за первые дни.

Набор данных

В распоряжении имеется датасет из 458 219 уникальных клиентов и 51 признака. Данные включают:

- статические характеристики (возраст, доход, образование и др.);
- поведенческие показатели (обороты, портфели, количество сделок, социальная активность);
- временные метки (дата открытия счета, дата первого использования).

2. Выбор метрики для измерения качества

Метрика

Основной метрикой качества выбрана F1-score.

Обоснование

Классы «активный инвестор» и «неактивный инвестор» сильно несбалансированы (активных клиентов значительно меньше). В такой ситуации метрика accuracy становится неинформативной, так как модель может предсказывать всех как «неактивных» и показывать высокую точность, не принося бизнесу пользы.

F1-score, являясь средним гармоническим между точностью (precision) и полнотой (recall), балансирует два важных для бизнеса аспекта:

- Полнота показывает, какую долю реально активных клиентов модель сможет обнаружить - критично для того, чтобы не упустить перспективных инвесторов.
- Точность показывает, какая доля предсказанных активных клиентов действительно окажется таковыми - важно для эффективного использования маркетингового бюджета.

F1-score наилучшим образом отражает компромисс между этими целями и позволяет оценить модель с точки зрения бизнеса

EDA (прилагается)

Далее представлен выполненный разведочный анализ данных (EDA), который включает:

- базовые характеристики датасета (размер, типы данных, пропуски, дубликаты);
- описательные статистики;
- визуализации (распределение возраста, активность vs доход, семейный статус, образование, размер портфеля);
- интерпретацию результатов, выводы и предложения по дальнейшей обработке.

[Копия блокнота "Разведочный анализ данных \(EDA\)" - Colab](#)

ссылка на данные: <https://dano.hse.ru/mirror/pubs/share/987943358.rar>